

Report

Data Science Challenge - Makasí

Thiago Assimós

Neste projeto foram usadas as seguintes prescrições com diferentes aplicações:

- Data set completo, onde foram feitas perturbações em torno dos valores originais usando como base os três projetos;
- Data Set com aplicação do VIF devido a alta correlação entre algumas variáveis;
- Data set com aplicação da PCA para verificar quantos componentes principais são relevantes para a análise, pelo mesmo motivo descrito acima.

Em cada um destes três conjuntos foram aplicados três modelos: Regressão Linear, Random Forest Regressor e uma Rede Neural.

Para avaliar a melhor performance utilizei as métricas RMSE (Root Mean Squared Error), MAE (Mean Absolute Error) e r^2 (coeficiente de determinação) e os valores do custo total dos projetos 1, 2 e 3 a fim de comparar com os valores preditos pelos modelos. Sendo assim, o modelo que apresentou os melhores resultados foi do **Random Forest Regressor no Data set sem aplicação do VIF e da PCA**, cujos resultados seguem abaixo:

1. Projeto 1: R\$ 3.153.078,84
2. Projeto 2: R\$ 2.573.481,67
3. Projeto 3: R\$ 4.594.623,32
4. Projeto 4: R\$ 3.463.660,79

Métricas

- RMSE: R\$ 149.885,09
- MAE: R\$ 121.670,49
- r^2 : 0.97

Abaixo segue os **valores reais** dos projetos 1, 2 e 3:

Projeto 1: R\$ 3.155.184,51

Projeto 2: R\$ 2.570.901,95

Projeto 3: R\$ 4.569.025,15

A partir daí, podemos ver que a **diferença de valor entre cada projeto** foi de:

Projeto 1: R\$ 2.105,67

Projeto 2: R\$ 2.579,72

Projeto 3: R\$ 25.598,17

Se analisarmos o percentual do RMSE e MAE, em relação aos valores de cada projeto temos, respectivamente:

Projeto 1: RMSE = 4,8% e MAE = 3,8%

Projeto 2: RMSE = 5,8% e MAE = 4,7%

Projeto 3: RMSE = 3,2% e MAE = 2,6%

Projeto 4: RMSE = 4,3% e MAE = 3,5%

Com isso podemos inferir que, apesar dos altos valores monetários, vemos que a margem de erro é aceitável. Veja que as diferenças dos valores reais e preditos não é tão alta, mas quando usamos o RMSE principalmente, que toma a raiz quadrada da soma de todos os quadrados da diferença entre os valores reais e preditos e divide pelo número de amostras, imagina isso aplicado em diferenças da ordem de R\$ 10.000,00 por exemplo.

Os gráficos das regressões mostraram bons ajustes, e isso podemos ver pelo valor do coeficiente de determinação r^2 .

Apesar de ter aplicado VIF e PCA, posso concluir que não é interessante remover variáveis ou reduzir a dimensionalidade.

Um outro ponto a se dicutir é sobre possíveis valores discrepantes das variáveis. Estes podem produzir grandes variações nas estimativas, pois *outliers* geram vieses no modelo –principalmente no caso de Regressão Linear–, redução da pre-

cisão, dentre outros problemas. Entretanto, isso não foi detectado neste modelo, mas é importante observar para futuras análises. Por exemplo, digamos que tivéssemos valores muito discrepantes na variável “Área do Terreno”, certamente precisaríamos analisar cada caso para ver como tratar esses dados, pois deixá-los da mesma forma poderia impactar negativamente nos resultados do modelo.

É importante discutir de forma resumida que está por trás do RMSE, MAE, r^2 , e dos modelos de Regressão Linear, Random Forest e Rede Neural usados neste projeto.

Apêndice

RMSE

É a raiz quadrada da média dos erros quadrados entre os valores previstos ($\hat{y}_i$) e os valores reais (y_i). É calculado da seguinte forma:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2},$$

onde:

n é o número de observações;

y_i são os valores reais;

$\hat{y}_i$ são os valores previstos pelo modelo.

MAE

É a média das diferenças absolutas entre os valores previstos ($\hat{y}_i$) e os valores reais (y_i). É calculado da seguinte forma:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|,$$

onde:

n é o número de observações;

y_i são os valores reais;

$\hat{y}_i$ são os valores previstos pelo modelo.

Coeficiente de determinação r^2

É uma medida descritiva da proporção da variação de uma variável (independente) que pode ser explicada por variações de outra variável (dependente). Assumindo que x é nossa variável independente e y a variável dependente, o coeficiente de determinação é calculado da seguinte forma,

$$r^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2},$$

onde:

n é o número de observações;

y_i são os valores reais;

$\hat{y}_i$ são os valores previstos pelo modelo;

$\bar{y}$ é a média dos valores reais.

Regressão Linear

É um método estatístico usado para modelar a relação entre uma variável dependente (alvo) e uma ou mais variáveis independentes (preditores). O objetivo é ajustar uma linha (ou um hiperplano em dimensões superiores) que minimize a soma dos erros quadráticos entre os valores reais e os valores preditos.

Para uma variável independente x e uma variável dependente y , o modelo de Regressão Linear Simples é definido como:

$$y = \alpha_0 + \alpha_1 x + \epsilon,$$

onde:

y é a variável dependente.

x é a variável independente.

α_0 é o intercepto.

α_1 é o coeficiente de inclinação.

ϵ é o termo de erro (resíduo).

O objetivo é encontrar os coeficientes $\alpha_0, \alpha_1, \dots, \alpha_p$ (para o caso de múltiplas variáveis) que minimizem a soma dos erros quadráticos (SSE):

$$\text{SSE} = \sum_{i=1}^n (y_i - \hat{y}_i)^2,$$

onde $\hat{y}_i$ é o valor predito pelo modelo para a i -ésima observação.

Random Forest Regressor

É um algoritmo de aprendizado de máquina baseado em árvores de decisão. Para a regressão, ele constrói múltiplas árvores de decisão e combina suas previsões para obter um resultado mais robusto e preciso. Cada árvore é construída a partir de um subconjunto aleatório dos dados de treinamento e das variáveis preditoras, o que ajuda a reduzir o sobreajustamento (overfitting) e a aumentar a generalização.

1) Cada árvore é construída a partir de um subconjunto aleatório dos dados de treinamento (com substituição, processo conhecido como bootstrap sampling).

2) Em cada nó da árvore, um subconjunto aleatório das variáveis preditoras é escolhido, e a melhor divisão é selecionada com base em um critério de impureza (para regressão, geralmente o erro quadrático médio).

3) Para uma nova observação, a previsão de uma única árvore de decisão é a média dos valores da variável dependente nas folhas onde a observação cai.

4) Para o Random Forest, a previsão final é a média das previsões de todas as árvores de decisão no conjunto.

Matematicamente, se tivermos T árvores no Random Forest, a previsão $\hat{y}$ para uma nova observação é:

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T \hat{y}^{(t)},$$

onde $\hat{y}^{(t)}$ é a previsão da t -ésima árvore.

Redes Neurais

O modelo Sequential implementado como a rede neural deste projeto pode ser representado como uma composição de funções, onde cada camada da rede neural é uma função que transforma os dados de entrada em uma representação intermediária, que é então passada para a próxima camada. Por exemplo, para um modelo sequencial com L camadas.

Seja x o vetor de entrada, $x^{(l)}$ o vetor de saída da camada l e $W^{(l)}$ e $b^{(l)}$ os pesos e o vetor de bias da camada l , respectivamente. A saída da camada l é calculada da seguinte forma:

$$x^{(l)} = f^{(l)}(W^{(l)}x^{(l-1)} + b^{(l)}),$$

onde:

$x^{(0)} = x$ é o vetor de entrada;

$f^{(l)}$ é a função de ativação da camada l ;

$W^{(l)}$ é a matriz de pesos da camada l ;

$b^{(l)}$ é o vetor de bias da camada l ;

$x^{(l-1)}$ é a saída da camada anterior.

Para o caso da última camada L , que produz a saída final $\hat{y}$ (a previsão), temos:

$$\hat{y} = f^{(L)}(W^{(L)}x^{(L-1)} + b^{(L)}).$$

Durante o treinamento, os pesos $W^{(l)}$ e os bias $b^{(l)}$ são ajustados iterativamente usando algoritmos de otimização, como gradiente descendente, para minimizar uma função de perda em relação aos rótulos de treinamento.